



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS DE RUSSAS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

JARDEL TORRES CHAGAS

**UMA METAHEURÍSTICA ADAPTADA AO PROBLEMA DE DETERMINAÇÃO DO
CAMINHO DE CORTE DE UM LEIAUTE COM TEMPO MÍNIMO**

RUSSAS
Agosto, 2021

JARDEL TORRES CHAGAS

UMA METAHEURÍSTICA ADAPTADA AO PROBLEMA DE DETERMINAÇÃO DO
CAMINHO DE CORTE DE UM LEIAUTE COM TEMPO MÍNIMO

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da computação
do CAMPUS DE RUSSAS da Universidade
Federal do Ceará, como requisito parcial à
obtenção do grau de bacharel em Ciência da
computação.

Orientador: Prof. Dr. Bonfim Amaro Júnior

RUSSAS

Agosto, 2021

LISTA DE ILUSTRAÇÕES

Figura 1 – Problema de determinação do caminho de corte.	8
Figura 2 – Fluxograma algoritmo genético	10
Figura 3 – Como os pais são selecionados	11
Figura 4 – fluxograma do algoritmo <i>Golden Ball</i>	12
Figura 5 – Resultados obtidos no trabalho (OSABA <i>et al.</i> , 2016)	15
Figura 6 – Representação do jogador	16

LISTA DE TABELAS

Tabela 1 – divisão dos jogadores	12
--	----

SUMÁRIO

1	INTRODUÇÃO	5
2	OBJETIVOS	7
2.1	Objetivo geral	7
2.2	Objetivos específico	7
3	FUNDAMENTAÇÃO TEÓRICA	8
3.1	Problema de determinação do caminho de corte	8
3.2	Algoritmos Evolutivos	9
3.2.1	<i>Algoritmo genético Clássico</i>	9
3.2.2	<i>Algoritmo Genético de Chaves Aleatórias Tendenciosas (BRKGA)</i>	11
3.3	Metaheurística <i>Golden Ball</i>	11
4	TRABALHOS RELACIONADOS	14
5	PROCEDIMENTOS METODOLÓGICOS	16
5.1	<i>Golden Ball</i> aplicado ao problema de determinação do caminho de corte	16
5.2	Implementação, validação e testes	17
5.3	Cronograma de execução	18
	REFERÊNCIAS	19

1 INTRODUÇÃO

Após a revolução industrial a manufatura vem sendo substituída pela maquinofatura. Há destacados investimentos em máquinas para a realização de trabalhos, que até então, eram feitos de maneira artesanal. Em tese, as máquinas reduzem riscos, melhoram a qualidade de trabalho e diminuem o tempo de produção fabril. Ainda assim, é possível investigar a maquinofatura além da melhora dos dispositivos (*hardware*). Por exemplo, empresas que operam nos setores de construção civil, fabricação e transporte de móveis, do vestuário e na indústria naval, deparam-se, diariamente, com problemas relacionados ao corte de itens menores que devem ser extraídos de uma peça maior.

Nesse contexto, surgiram pesquisas voltadas para a camada de *software* inerente dos equipamentos automatizadores considerando algoritmos exatos ou heurísticos. Profusas abordagens representando problemas evidenciados nas indústrias pertencem a classe NP-difícil (WäSCHER *et al.*, 2007), ou seja o problema não é resolvido em tempo polinomial. Caso do problema de determinação do caminho de corte de um leiaute buscando tempo mínimo. Em escala industrial, a solução sobre instâncias desse problema se torna inviável em tempo computacional hábil, no escopo de métodos computacionais exatos (modelos matemáticos).

Dessa forma, estudos voltados para algoritmos heurísticos e metaheurísticas são motivados na busca de soluções factíveis e de qualidade destacada. Esse trabalho apresenta uma variante do problema determinação do caminho de corte, focado na fase posterior à definição de um leiaute considerando, ainda, parâmetros de um dispositivo de corte: a velocidade de movimentação da cabeça quando está cortando ou não.

Diante do exposto, é fundamental definir a trajetória de corte que minimize o tempo em uma variação de máquinas de corte como: laser, plasma, oxicorte e jato d'água. Esses equipamentos possuem variações de acordo com o tipo do material a ser cortado, a potência significativa, bem como o tempo de deslocamento para a mover o bico de corte, ou seja, a movimentação sem que esteja cortando, que decorre da capacidade de translação para todos os eixos, comumente agindo independentemente (DEWIL *et al.*, 2016).

Diante dessas ponderações, esse trabalho apresentará um estudo fundamentado em outra pesquisa sobre duas abordagens para a determinação do caminho de corte de um leiaute com tempo mínimo: um algoritmo genético clássico e, em especial, o algoritmo genético de chaves aleatórias tendenciosas (BRKGA). Este, por sua vez, obteve melhores resultados.

Na pesquisa abordada iremos utilizar o algoritmo *Golden Ball*(seção 3.3) para a

resolução do problema de determinação do caminho de corte, em que cada jogador é uma representação de uma resposta (seção 5.1) inicialmente geradas de forma aleatória. Para a execução do algoritmo necessita de duas variáveis de entradas V_m e V_c que representa respectivamente, velocidade de movimentação da cabeça, ou seja, velocidade em que a cabeça se movimenta sem cortar algo, e a velocidade de Corte. Criado os times (seção 3.3) variáveis de entradas definidas agora basta seguir o fluxo da metaheurística (Figura 4)

Uma comparação entre os resultados obtidos pela adaptação da metaheurística multipopulacional *Golden Ball* (OSABA *et al.*, 2013) aplicada ao problema desse estudo também será realizada (NEPOMUCENO *et al.*, 2020).

2 OBJETIVOS

Os objetivos da pesquisa científica representam, além das metas propostas para o estudo do projeto, mecanismo de obtenção de resultados mediante o trabalho realizado. Dessa forma, nessa seção serão expostos os objetivos de cunho geral (seção 2.1) considerando a investigação da metaheurística *Golden Ball* (GB) no contexto do problema de determinação de corte com tempo mínimo e, alvos específicos (seção 2.2) para concluir a pesquisa de forma satisfatória.

2.1 Objetivo geral

O objetivo deste trabalho é investigar o problema de determinação do caminho de corte aplicando a metaheurística *Golden Ball* (GB), para estabelecer uma ordem de corte com o menor tempo possível para as arestas de todos os polígonos, representações computacionais de itens de uma demanda preestabelecida de um tipo de insumo.

2.2 Objetivos específico

- Analisar o problema de determinação do caminho de corte
- Analisar algoritmos genéticos clássico
- Analisar algoritmo genético de chaves aleatórias tendenciosas
- Investigação de conceitos inerentes às heurísticas e metaheurísticas
- Aplicar a metaheurística *Golden Ball* ao problema de determinação do caminho de corte
- Melhorar o tempo mínimo de corte de uma máquina de corte
- Comparar os resultados apresentados com pesquisas já desenvolvidas na literatura


3 FUNDAMENTAÇÃO TEÓRICA

Nessa seção será demonstrada todos os fundamentos teóricos necessário para a execução do trabalho. Primeiramente, a seção 3.1 mostra o Problema de determinação do caminho de corte que será problema investigado pelo trabalho, posteriormente será introduzido os Algoritmos Evolutivos seção 3.2 dando uma ênfase nos algoritmos genéticos clássico seção 3.2.1 e nos algoritmo Genético de Chaves Aleatórias Tendenciosas seção 3.2.2. Por fim, a seção 3.3 demonstrando a teoria por trás da Metaheurística *Golden Ball*, que será aplicada ao problema de determinação do caminho de corte.

3.1 Problema de determinação do caminho de corte

Com destacada fundamentação para esta pesquisa, (LEE; KWON, 2006) e (HAN; NA, 1999) apresentaram o problema da determinação do caminho de corte (CPDP). O principal objetivo desta aplicação prática é estabelecer uma sequência de movimentos para um equipamento, de modo que todos os itens posicionados na superfície sejam devidamente separados (NEPOMUCENO *et al.*, 2020). Neste processo existem duas fases importantes, a primeira é a geração de um leiaute otimizado, ou seja, o encaixe das peças a serem retiradas de forma a minimizar o desperdício de insumos, e a segunda fase consiste em otimizar a definição da ordem do corte, ou seja, definir qual sequência uma determinada máquina de corte deve seguir para minimizar o tempo de extração de peças. Na figura 1 apresenta a representação para uma instância do problema supracitado.

Figura 1 – Problema de determinação do caminho de corte.



Dada uma demanda que já passou pela fase de geração do leiaute, no trabalho gera-se um grafo não direcionado, como mostrado na figura 1. Um grafo não direcionado é um tipo abstrato de dado (TAD) que é a relação de adjacência é simétrica, por exemplo, a resta (A, B) é igual a (B, A). Seja um grafo $G = (V, E)$ em que G é formado por uma 2-upla, onde V é um conjunto de vértices ou nós, tomando a figura 1 como exemplo, o conjunto de vértice é definido por $V = A, B, C, D, E, F, G, H, I, J, K, L$ o conjunto de aresta é representado por um conjunto de pares, seja $E = (A, B), (A, H), (B, C), (B, I), (B, L), (C, D), (D, L), (D, K), (D, E), (E, F), (F, K), (F, J), (F, G), (G, H), (H, I), (I, L), (I, J), (L, K), (K, J)$. A aplicação de metaheurísticas evolutivas é uma ferramenta de destacada aplicação para resolver problemas com características combinatórias. Assim, este trabalho foca na investigação desse paradigma, bem como, a vertente multipopulacional do algoritmo *Golden Ball*.

3.2 Algoritmos Evolutivos

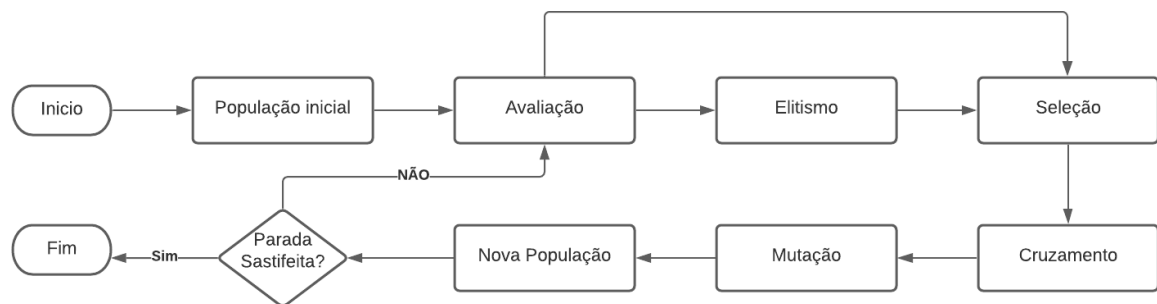
Existem muitas variantes diferente de algoritmos evolutivos, mas todos partem de uma ideia em comum: “dada uma população de indivíduos dentro de algum ambiente com recursos limitados, a competição por esses recursos causa a seleção natural (sobrevivência do mais apto).” (EIBEN; SMITH, 2003) O algoritmo genético clássico (seção 3.2.1) é um algoritmo evolutivo fundamental para o entendimento dos processos evolutivos computacionais, tendo inúmeras variações dentre delas o (BRKGA) algoritmo genético de chaves aleatória tendenciosas (seção 3.2.2).

3.2.1 Algoritmo genético Clássico

Algoritmo genético Clássico, ou simplesmente Algoritmo genético (AG) representam uma analogia computacional em relação à teoria da evolução natural de Darwin. Os AG's foram introduzidos por J. Holland em 1975 e funcionam da seguinte forma: geralmente inicializa a população com indivíduos cujo seus cromossomos são aleatórios e o tamanho da população varia de acordo com a necessidade do problema e está diretamente ligado ao fato de que quanto maior a população maior será o tempo de execução, ou seja, no tempo computacional. Ainda, para avaliar quais são os melhores indivíduos, passa-se por uma função de *fitness*, função de avaliação nos AG's, que dá uma pontuação para cada indivíduo com base nos critérios modelados na função nessa avaliação. Além disso, há as fases de elitismo e seleção, cada indivíduo com

sua avaliação devida, será selecionado para o cruzamento e mutação, gerando assim uma nova população. Uma estratégia interessante para selecionar geracionalmente esses indivíduos pode ser por meio do elitismo, que se configura com o descarte de soluções com a avaliação baixa. É importante frisar que a fase de elitismo pode ser removida (opcional), portanto vai depender da estratégia para o problema. Para selecionar os pais existem alguns métodos como o da roleta (LIPOWSKI; LIPOWSKA, 2011) e torneio (THIERENS; GOLDBERG, 1994). O da roleta consiste em rodar uma roleta e cada indivíduo ocupa um espaço nessa roleta com forme a relação estabelecida ponto do indivíduo por ponto total da população e, no torneio, o indivíduo mais forte, com a melhor função de avaliação é o vencedor, ou seja, o escolhido na imagem a seguir mostra uma variante do fluxograma de um AG.

Figura 2 – Fluxograma algoritmo genético



Fonte: Adaptado Usida *et al.* (2021)

Na fase do cruzamento (DESHPANDE; KELKAR, 2008) geram-se dois filhos combinados em um determinado intervalo dos pais, assim como na natureza existe uma pequena chance de mutação nos seres de uma espécie, porem devemos ter cuidado para não ter uma taxa muito pequena pois pode deixar o processo preso em ótimos locais, no AG também deve-se ter esse operador primordial, mas também tendo cuidado de não colocar uma taxa de mutação muito alta pois pode gerar um efeito de aleatoriedade. assegurando uma varredura mais expansiva do espaço de busca. Após ser aplicado os operadores de mutação gera-se uma nova população, caso o critério de parada seja alcançado o algoritmo termina, tendo como resultado o melhor indivíduo da última população, caso contrário volta-se para a fase de avaliação e fica nesse ciclo o critério de parada ser alcançado.

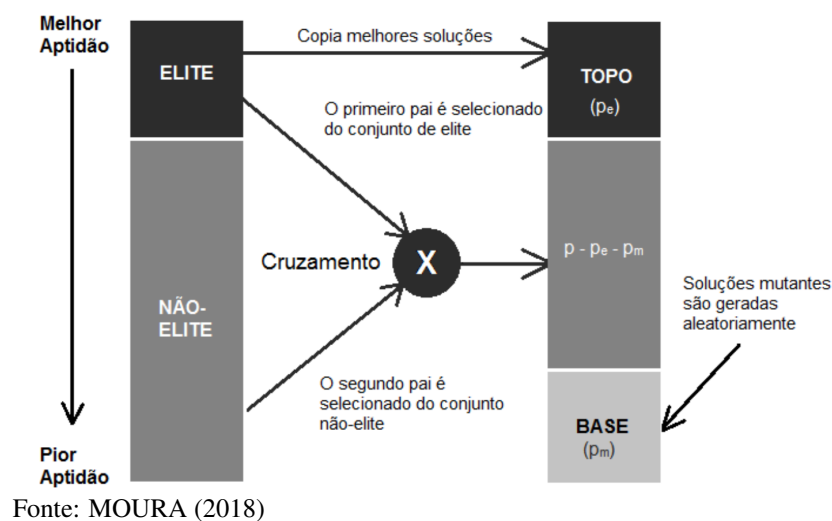
A figura 2 representa uma variação do algoritmo genético, a fase de elitismo não é uma fase obrigatória para os algoritmos genéticos clássicos, mas é uma fase primordial para o Algoritmo Genético de Chaves Aleatórias Tendenciosas (BRKGA).

3.2.2 Algoritmo Genético de Chaves Aleatórias Tendenciosas (BRKGA)

Os algoritmos genéticos com chaves aleatórias tendenciosas (BRKGA) foram propostos por (RESENDE, 2010) contemplando uma variação dos algoritmos genéticos com chaves aleatórias (RKGA)(BEAN, 1994), sua principal distinção é a forma como os pais são selecionados, pois sempre será selecionado um pai que faz parte do conjunto dos indivíduos da elite e o outro pai selecionado pertence ao grupo de não elite, a figura 3 demonstra como isso é feito. Esse método descrito com fase de elitismo no processo de seleção é responsável por expandir a chance de interação dos indivíduos mais aptos nos métodos de cruzamento. Uma das grandes vantagens foi descrita por (NEPOMUCENO *et al.*, 2020)

Uma das vantagens de utilização do BRKGA vem da sua tolerância a diversos problemas de otimização, assumindo que dois elementos do seu arcabouço devem ser representados: um decodificador compatível e uma função de aptidão representativa.

Figura 3 – Como os pais são selecionados




3.3 Metaheurística Golden Ball

O algoritmo *Golden Ball* é uma metaheurística que opera sobre o conceito de metaheurísticas multipopulacionais e estratégias relacionadas ao futebol. Bola de Ouro (no original em francês *Ballon d'Or*) é um prêmio de futebol introduzido pela revista francesa *France Football*. Curiosamente, essa distinção já foi conhecida mundialmente como Futebolista do Ano na Europa, sendo entregue de forma independente entre 1956 e 2009 e novamente a partir de 2016, após fim da parceria com a Federação Internacional de Futebol (FIFA). A figura 4 apresenta o fluxograma

do método (OSABA *et al.*, 2013).

Figura 4 – fluxograma do algoritmo *Golden Ball*



Fonte: adaptado (OSABA *et al.*, 2013).

Em termos computacionais, preliminarmente cria-se a população inicial que é um conjunto de soluções introdutórias, como qualquer outro algoritmo evolutivo, mas no *Golden Ball*, esse processo refere-se à criação de jogadores, e a divisão em subpopulação é responsável pela formação dos times.

De acordo com (OSABA *et al.*, 2013), a definição do tamanho da população é calculada por $P = T_n * P_t$. O termo T_n informa os números de times na liga e P_t o número de jogadores de cada time. O próximo passo é referente à fase da divisão dos jogadores formando, assim, os times que podem ser representados por uma matriz, veja a tabela 1. Cada jogador é representado por P_{ij} , ou seja, jogador i no plantel j .

Tabela 1 – divisão dos jogadores

L/C	1	2	3	...	P_t
1	P_{11}	P_{12}	P_{13}	...	$P_1 P_t$
2	P_{21}	P_{22}	P_{23}	...	$P_2 P_t$
3	P_{31}	P_{32}	P_{33}	...	$P_3 P_t$
...
T_n	PT_{n1}	PT_{n2}	PT_{n3}	...	$P_{TN} P_t$

Fonte: Adaptado Osaba *et al.* (2013)

Agora precisamos calcular a força do time, esse valor será usado nas partidas para

determinar o vencedor do jogo, conceito semelhante de uma função de custo, de outro modo, a função de aptidão dos algoritmos genéticos. O jogador com maior qualidade (ou aptidão) será denominado de capitão do time.

A fase de treinamento tem objetivo de qualificar os jogadores, ou seja, tenta elevar a força individual e, conseqüentemente, aumentar a força do time. Os times jogam entre si como em uma liga, que irá ranquear influenciando, assim, uma fase posterior, a fase de transferência.

A liga dura $2T_n - 2$ jogos. Cada time se enfrenta duas vezes e tem P_t chances de fazer gol. Cada chance é calculada por meio do método de torneio entre p_{ij} . Cada jogador da equipe se enfrenta de acordo com um ranque interno de cada time, esse ranque é quem define o capitão, pois quem tem mais pontos é o primeiro no ranque e conseqüentemente é o capitão, os capitães dos times vão se enfrentar, os segundos no ranque vão se enfrentar e assim em diante até chegar no jogador na posição P_t . O jogador que ganhar o torneio ganha o gol. A liga como na vida real premia o ganhador da partida com três pontos e o perdedor fica com zero pontos e em caso de empates cada equipe fica com um ponto, esses pontos são somados até o fim da temporada, definindo os melhores times. Após o final da temporada verifica se o critério de parada foi alcançado caso não tenha sido alcançado começa o período de transferências, os times da metade superior fazem aquisição do melhor jogador dos times da metade inferior da tabela e os times da metade inferior se contenta com os menos bons dos times da parte de cima

4 TRABALHOS RELACIONADOS

Nessa seção será apresentada uma revisão da literatura existente sobre o problema investigado nesse artigo. De antemão, avisamos ao leitor que esta revisão é focada nos métodos para resolver o problema de determinação do caminho de corte e o uso do algoritmo *Golden Ball*.

O problema de determinação do caminho de corte é objeto de estudo de abundantes pesquisas. (HAN; NA, 1999) tratam o problema dessa forma: percorrer os contornos do corte com um comprimento mínimo de percurso e minimizar o efeito do calor gerado pelo equipamento (tubo) na sequência do percurso de corte. Para isso, a temperatura crítica deve ser evitada durante o procedimento. Uma estrutura similar ao (*Traveling Salesman Problem* - TSP) é resolvida por meio de um algoritmo fundamentado na metaheurística Têmpera Simulada (*Simulated Annealing*) para otimizar o planejamento do caminho de corte. O efeito do calor é incorporado à função de custo com base no modelo analítico modificado de condução de calor, também, apresentado em (HAN; NA, 1999).

No trabalho de (OSABA *et al.*, 2016) a meta-heurística *Golden Ball* (GB) foi comparada com os algoritmos *Evolutionary Simulated Annealing* (ESA) e o *Tabu Search* (TS) aplicado ao problema do caixeiro viajante. O principal objetivo do trabalho de (OSABA *et al.*, 2016) era confirmar que o GB pode competir com alguns das técnicas mais utilizadas da literatura. A Figura 5, a seguir mostra a tabela de resultados obtidos pela pesquisa. Nos testes foram usados 16 instancias com 50 a 144 nós, geradas por (REINELT, 1991). Cada instancia foi executada 30 vezes e o GB obteve melhores resultados do que o ESA e TS em 81,25% dos testes realizados na pesquisa.

No trabalho de (NEPOMUCENO *et al.*, 2020), os autores utilizaram uma variante do problema de determinação do caminho de corte utilizando o algoritmo genético clássico e o algoritmo genético com chaves tendenciosas para gerar os caminhos de corte, com sua execução em uma máquina de corte a laser. Os melhores resultados obtidos foram usando o algoritmo BRKGA tendo uma melhora significativa de 60% em leiautes empacotadas, e uma melhora de 20% em leiautes contendo itens separados no espaço. A melhor configuração para a execução do algoritmo foi, tamanho da população com 5000 indivíduos com 30% desses indivíduos pertencente ao grupo elite e com 10% dos indivíduos mutáveis. Utilizando a distância de Chebyshev para calcular o tempo entre os vértices de corte e seus possíveis deslocamentos.

Figura 5 – Resultados obtidos no trabalho (OSABA *et al.*, 2016)**TSP.**

Instância	ESA			TS			GB		
Nome	Avg. S. dev. Tempo			Avg. S. dev. Tempo			Avg. S. dev. Tempo		
Eilon50	427.6	1.7	1.5	427.8	1.6	1.4	427.2	1.5	1.1
Eil51	431.6	2.9	1.7	428.9	1.4	1.5	428.6	1.3	1.4
Berlin52	7542.0	0.0	2.1	7542.0	0.0	2.2	7542.0	0.0	2.1
St70	679.1	2.8	3.9	679.2	3.4	4.1	679.4	3.5	4.2
Eilon75	550.2	3.9	4.5	552.3	3.7	4.7	544.3	3.3	5.4
Eil76	553.7	4.2	5.1	545.1	3.4	5.4	547.3	3.7	5.5
KroA100	21481.7	150.1	10.6	21495.4	120.9	10.1	21386.7	99.7	9.5
KroB100	22602.2	210.2	11.1	22612.8	205.8	10.7	22311.0	139.6	9.7
KroC100	21170.4	188.7	12.0	21192.6	166.6	12.3	20968.2	111.3	9.3
KroD100	21726.5	156.9	11.7	21761.3	155.4	11.2	21485.8	188.2	9.7
KroE100	22499.7	171.4	11.4	22534.8	175.5	10.9	22266.8	158.1	9.8
Eil101	656.4	4.4	11.7	658.0	5.1	11.4	645.7	4.3	8.9
Pr107	44821.5	179.3	12.1	44834.3	227.0	11.8	44693.0	210.7	10.1
Pr124	59593.6	367.8	18.5	59560.4	453.1	17.9	59348.2	190.3	16.2
Pr136	99864.4	655.7	23.4	99802.3	914.2	23.0	98906.5	986.7	23.7
Pr144	58807.3	220.9	33.9	58973.1	762.4	32.7	58712.0	247.7	34.1

Fonte: (OSABA *et al.*, 2016)

5 PROCEDIMENTOS METODOLÓGICOS

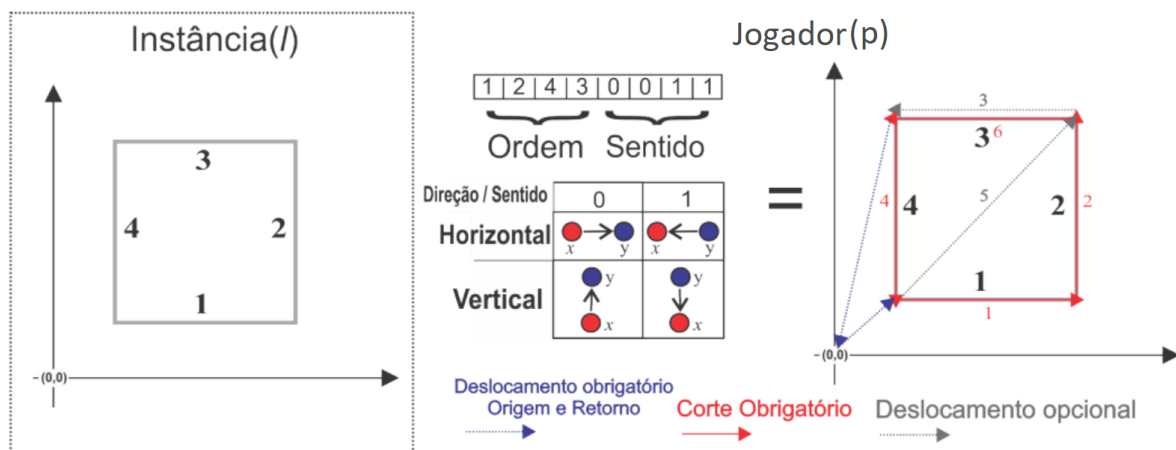
Nessa seção será demonstrado os procedimentos metodológicos a serem desenvolvidos nesta pesquisa.

5.1 *Golden Ball* aplicado ao problema de determinação do caminho de corte

Como a estratégia *Golden Ball* é uma metaheurística evolutiva, o primeiro passo foi realizar uma revisão bibliográfica na literatura que tratava, não somente, da variação do problema de determinação do caminho de corte sob a ótica dos algoritmos mediante mesmo paradigma, mas também de possíveis adaptações. Com isso em mente, uma maneira de modelar o problema é suscitada nesta seção.

Assim como no trabalho de (NEPOMUCENO *et al.*, 2020) a execução será em uma máquina de corte a laser que desloca por coordenadas (x, y). Como parâmetros de entrada será definido velocidade de movimentação da cabeça (V_m) e velocidade de corte (V_c). Esses valores podem variar conforme a necessidade dos equipamentos. Para calcular o tempo que uma máquina levaria para extrair peças dos insumos foi considerado a distância de Chebyshev e dependendo da ação tomada pela máquina será escolhido V_m representado pela seta cinza na figura 6 ou V_c representado pela seta vermelha ilustrado também pela figura 6.

Figura 6 – Representação do jogador



Fonte: Adaptado de Nepomuceno *et al.* (2020)

Definido as entradas, agora é a definição dos jogadores, cada jogador é criado aleatoriamente e são colocados em T_n times também de forma aleatória. A representação dos jogadores é dividida em duas partes, como apresenta a figura 6. A primeira metade do vetor

informa a ordem de corte e a outra metade, o sentido do corte escolhido pela máquina. Dessa forma, a qualidade dos jogadores e, consequentemente, a qualidade dos times está ligada ao tempo de corte de um leiaute, ou seja, quanto mais rápido realizar o corte, maior será a qualidade do jogador. Durante a competição há duas etapas fundamentais para o algoritmo, o método de treino e as partidas que darão *ranking* para os times e esse *ranking* é utilizado na fase de transferência.

Na fase de treino os jogadores são submetidos a aplicação métodos para melhorar sua performance nas partidas. Isso mantém um caráter semelhante ao mundo real. Cada equipe pode possuir um método de treino distinto, e dessa forma, esse mecanismo será atribuído de forma aleatória na criação dos times. "A saber, uma função sucessora que atua em uma determinada estrutura de vizinhança no espaço de solução para certos problemas de roteamento, uma função desse tipo poderia ser a conhecida 2-opt ou 3-opt"(OSABA *et al.*, 2013). A aplicação desta função pre escolhida pode ser realizada um numero x de vezes para cada treino objetivando melhorar um conjunto determinado de jogadores.

Cada equipe possui um treino personalizado que tem como objetivo fugir de ótimos locais, esse treino personalizado acontece quando um jogador não melhora a um numero determinado de treinos, o que faz ele treinar com o capitão do time, nesse treino acontece uma variação do "*crossover*". O jogador que está precisando de treino recebe metade (possivelmente parametrizado) das características do capitão do time.

Os jogos consistem em P_i chances de gols, cada chance se efetiva em gol por meio de um torneio entre os jogadores dos times. Como cada time tem a lista de jogadores ordenados pela aptidão, a lógica do processo é organizada com a relação entre melhores disputando em pares pelo gol (ponto).

Por fim, o período de transferência de jogadores. Nesse contexto, os times que obtiveram melhores posições na tabela escolhe os melhores jogadores dos times da metade de baixo, sendo que o melhor time pega o melhor jogador do pior time e o segundo time pega o melhor jogador do penúltimo time e assim por diante. Todos esses processos vão se repetir até que o critério de parada seja alcançado.

5.2 Implementação, validação e testes

A implementação começará em setembro como mostra o cronograma (5.3). Com o intuito de validar e testar as instâncias propostas, todos os testes serão realizados em 20 instâncias

geradas por (JúNIOR *et al.*, 2017) com o propósito de expor uma comparação entre o BRKGA, que de acordo com a pesquisa realizada por (NEPOMUCENO *et al.*, 2020) foi o algoritmo que obteve melhores resultados, e o *Golden Ball* com a finalidade de investigar qual delas se saíram melhor, se é possível obter uma melhora de tempo com a metaheurística bola dourada (GB).

5.3 Cronograma de execução

[illegible]

REFERÊNCIAS

- BEAN, J. C. Genetic algorithms and random keys for sequencing and optimization. **ORSA Journal on Computing**, v. 6, n. 2, p. 154–160, 1994. Disponível em: <<https://doi.org/10.1287/ijoc.6.2.154>>.
- DESHPANDE, A.; KELKAR, R. Advanced genetic operators and techniques: an analysis of dominance diploidy, reordering operator in genetic search. In: . [S.l.: s.n.], 2008. p. 27–33.
- DEWIL, R.; VANSTEENWEGEN, P.; CATTRYSSSE, D. A review of cutting path algorithms for laser cutters. **The International Journal of Advanced Manufacturing Technology**, v. 87, p. 1865–1884, 11 2016.
- EIBEN, A. E.; SMITH, J. E. Genetic algorithms. In: _____. **Introduction to Evolutionary Computing**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003. p. 37–69. ISBN 978-3-662-05094-1. Disponível em: <https://doi.org/10.1007/978-3-662-05094-1_3>.
- HAN, G. C.; NA, S.-J. A study on torch path planning in laser cutting processes. part 2: Cutting path optimization using simulated annealing. **Journal of Manufacturing Systems**, v. 18, p. 62–70, 12 1999.
- JÚNIOR, B.; PINHEIRO, P.; COELHO, P. A parallel biased random-key genetic algorithm with multiple populations applied to irregular strip packing problems. **Mathematical Problems in Engineering**, v. 2017, p. 1–11, 09 2017.
- LEE, M.-K.; KWON, K.-B. Cutting path optimization in cnc cutting processes using a two-step genetic algorithm. **International Journal of Production Research**, Taylor Francis, v. 44, n. 24, p. 5307–5326, 2006. Disponível em: <<https://doi.org/10.1080/00207540600579615>>.
- LIPOWSKI, A.; LIPOWSKA, D. Roulette-wheel selection via stochastic acceptance. **Physica A: Statistical Mechanics and its Applications**, v. 391, 09 2011.
- MOURA, M. A. Algoritmo genético de chaves aleatórias segundo distribuição de levy para otimização global. Universidade Federal de Pernambuco, 2 2018.
- NEPOMUCENO, G.; SOARES, D. C.; SANTOS, K. B. dos; JUNIOR, B. A.; SANTOS, M. C. Abordagens evolutivas para determinação do caminho de corte de um leiaute com tempo mínimo. **ANAIIS DO LII SIMPÓSIO BRASILEIRO DE PESQUISA OPERACIONAL**, 9 2020.
- OSABA, E.; CARBALLEDO, R.; GARCÍA, P. L.; DIAZ, F. Comparison between golden ball meta-heuristic, evolutionary simulated annealing and tabu search for the traveling salesman problem. In: . [S.l.: s.n.], 2016.
- OSABA, E.; DÍAZ, F.; ONIEVA, E. Golden ball: A novel meta-heuristic to solve combinatorial optimization problems based on soccer concepts. **Applied Intelligence**, v. 41, p. 145–166, 12 2013.
- REINELT, G. Tsplib—a traveling salesman problem library. **ORSA Journal on Computing**, v. 3, n. 4, p. 376–384, 1991. Disponível em: <<https://doi.org/10.1287/ijoc.3.4.376>>.
- RESENDE, M. Biased random-key genetic algorithms with applications in telecommunications. **TOP**, v. 20, p. 130–153, 01 2010.

THIERENS, D.; GOLDBERG, D. Convergence models of genetic algorithm selection schemes. In: DAVIDOR, Y.; SCHWEFEL, H.-P.; MÄNNER, R. (Ed.). **Parallel Problem Solving from Nature — PPSN III**. Berlin, Heidelberg: Springer Berlin Heidelberg, 1994. p. 119–129. ISBN 978-3-540-49001-2.

USIDA, W.; COURY, D.; FLAUZINO, R.; SILVA, I. Alocação de dispositivos indicadores de faltas em alimentadores primários usando algoritmos genéticos. 08 2021.

WäSCHER, G.; HAUßNER, H.; SCHUMANN, H. An improved typology of cutting and packing problems. **European Journal of Operational Research**, v. 183, p. 1109–1130, 12 2007.